

Week 09：文档解析与 Chunking

AI Agent 工程学习系统 · 本地可维护版本

源文件：WEEK_PLAN.md

目录

Week 09 : 文档解析与 Chunking 1

1. 本周目标 3

2. 对应岗位能力 3

3. 每日任务总览 3

4. 时间分配 3

5. 必须掌握 3

6. 需要理解 4

7. 暂时了解 4

8. 本周编码任务 4

9. 本周项目里程碑 4

10. 工程要求 4

11. 验收标准 4

12. 常见风险 4

13. 补做任务 4

14. 提前完成后的进阶任务 5

15. 本周面试问题 5

16. 周末复盘方式 5

17. 下周准备事项 5

1. 本周目标

- 建立对“文档加载、清洗、切块策略、重叠与元数据”的工作级理解。
- 完成：设计规范文档摄取流水线。
- 能结合项目解释本周至少两个技术取舍。

2. 对应岗位能力

RAG 质量首先取决于进入索引的数据结构。

3. 每日任务总览

日期	主题	方式	预计时间
Day 1	文档解析与 Chunking : 概念与最小示例	概念与最小示例	1.5 小时
Day 2	文档解析与 Chunking : 基础编码练习	基础编码练习	2.0 小时
Day 3	文档解析与 Chunking : 功能开发	功能开发	2.25 小时
Day 4	文档解析与 Chunking : 工程化改造	工程化改造	2.0 小时
Day 5	文档解析与 Chunking : 项目开发	项目开发	2.5 小时
Day 6	文档解析与 Chunking : 独立挑战与问题修复	独立挑战与问题修复	2.5 小时
Day 7	文档解析与 Chunking 复 习、复盘与补做	复习、整理和自由补充	1.5 小时

4. 时间分配

- 概念与示例：20%
- 编码与项目：55%
- 测试、文档与排查：15%
- 复习与自由补充：10%

5. 必须掌握

- 解析
- Chunk

- 重叠
- Metadata

6. 需要理解

- 语义切块
- 表格处理

7. 暂时了解

- 版面感知解析

8. 本周编码任务

- 在 weeks/week-09/exercises/ 完成最小练习。
- 在对应项目目录中完成一个可运行里程碑。
- 为关键成功路径和一个错误路径增加测试或验证脚本。

9. 本周项目里程碑

阶段项目：设计规范知识库 Agent：设计规范文档摄取流水线。

10. 工程要求

- Python 代码使用类型提示；配置不写死本地路径。
- API Key 只从环境变量读取；日志不记录完整密钥或敏感资料。
- 写清运行命令、输入输出、失败表现和验收方法。

11. 验收标准

- [] 交付物可以按 README 运行。
- [] 正常输入和至少一个错误输入被验证。
- [] 本周代码、测试、文档和进度记录均已更新。
- [] 能口头回答本周面试问题并引用项目例子。

12. 常见风险

直接套固定字符数，破坏章节语义。

13. 补做任务

- 如果本周末完成，先保留核心闭环：输入 -> 处理 -> 输出 -> 错误处理 -> 运行说明。
- 将非核心优化移到 Day 7 或下一周 REVIEW.md 的待办区。

14. 提前完成后的进阶任务

- 增加一个失败场景、性能指标或安全约束。
- 对比教学版与生产版差异，并写出一条架构决策记录。

15. 本周面试问题

1. Chunk 过大或过小有什么影响？
2. 元数据如何帮助检索？

16. 周末复盘方式

展示交付物 5 分钟；说明目标、实现、失败、修复和下一步；再填写 REVIEW.md。

17. 下周准备事项

确认当前代码已提交、环境可重建、未完成任务已记录，并预览下一周的产出定义。