

1 案例分流与合规助手：架构说明

1.1 架构目标

架构目标是将用户输入、确定性验证、模型/检索建议、工具调用和人工批准隔离为可测试组件。该项目的技术栈建议为：FastAPI、RAG、Tool Calling、LangGraph、评测、安全、部署。

1.2 组件与责任

组件	责任	不应承担的责任
API 层	认证入口、请求验证、响应契约	直接拼接数据库 SQL 或存放模型密钥
应用服务	编排用例、事务边界、状态转换	依赖具体 Web 框架细节
Agent/检索层	受控推理、检索、工具选择	直接执行未批准的外部副作用
工具适配层	参数验证、超时、重试、审计	绕过权限和人工确认
数据层	持久化业务状态、评测集、审计摘要	记录原始密钥或敏感提示词
观测层	日志、指标、追踪、成本	替代业务校验

1.3 数据与控制流

```
flowchart LR
    U[用户] --> A[FastAPI 输入验证]
    A --> S[应用服务与状态]
    S --> R[检索或规则]
    S --> M[模型建议]
    M --> T[受控工具适配层]
    T --> H{需要人工确认?}
    H -- 是 --> P[批准/拒绝节点]
    H -- 否 --> D[(PostgreSQL)]
    P --> D
    S --> O[结构化日志与评测]
```

1.4 关键边界

- 模型只能提出工具调用意图，应用代码负责 Schema 校验、权限验证和实际执行。
- 检索结果需要带来源标识；生成内容不得伪造引用。
- 高影响操作默认需要人工确认，并记录批准者、时间与依据。
- 密钥只存在于部署环境变量或秘密管理系统中；日志默认脱敏。

1.5 教学版与生产版

教学版使用本地示例数据、同步调用和最小日志，目的是学习组件边界。生产版需要认证、限流、队列/超时、持久化检查点、数据隔离、监控告警、备份与回滚。

1.6 参考资源索引